

Dokumentácia k úlohe č. 3

Podúloha 1

Cieľ zadania:

Návrh a architektúra neurónovej siete, ktorá má predpovedať vysoko volatilné ceny na trhu s kryptomenami na základe poskytnutého trénovacieho súboru údajov a testovať presnosť modelu pomocou testovacieho súboru údajov. Trénovací súbor údajov pozostáva zo série po sebe idúcich časových značiek, v ktorých je v každom bode posunutá sada predpovedaných hodnôt inými modelmi a podľa časovej značky, ako aj skutočná cena za daný deň.

Modelová architektúra

Navrhovaný model pozostáva z 3 primárnych výpočtových vrstiev a jednej aktivačnej vrstvy. Na optimalizáciu bola zvolená metóda ADAM (Adaptive Learning Rates). Funkcia straty je BCE (Binary Cross Entropy). Metóda ADAM bola zvolená, pretože umožňuje rôznym parametrom rásť alebo klesať podľa vlastných sklonov, čím sa zabráni prerušeniu v lokálnom minime. Okrem toho využíva hybnosť, aby sa rýchlejšie učil na strmších stranách učebnej roviny a pomalšie na rovnejších. Aktivačná funkcia sa používa na výstupe modelu, avšak nie počas trénovania, pretože BCE nie je navrhnutá na prácu s výstupom zo sigmoidnej aktivačnej funkcie. Ak by sa zaviedla, znížila by výkon modelu na nulu.

Hlavnými učiacimi sa vrstvami sú vrstvy buniek LSTM.

Vrstva LSTM je skupina buniek LSTM. Súčasná architektúra má v každej vrstve iba jednu bunku. Posledná vrstva je lineárna vrstva. Účelom poslednej vrstvy je transformácia výsledného vektora predchádzajúcej bunky LSTM na jednu hodnotu.

Aktivačná vrstva používa sigmoidnú funkciu na konverziu výsledku inferencie na číslo v použiteľnom rozsahu, konkrétne od 0 do 1. Ako bolo spomenuté vyššie, aplikuje sa na výstup forward metódy modelu.

Tu je tabuľka experimentov, ktoré som vykonal s cieľom nájsť optimálnu architektúru a zvýšiť celkový výkon modelu.

Tabuľka experimentov


Learning Rate	Batch Size	Sequence Length	Generation	Hidden layer size	Device	Accuracy Train (F1 Score)	Accuracy Test (F1 Score)	Exp. Num.
0.0004	15	20	50	64	cpu	60.66%	51.95%	1
0.0004	15	20	300	64	cpu	66.97%	49.61%	2
0.0004	15	20	50	128	cpu	61.64%	59.58%	3
0.0004	15	20	75	128	cpu	62.47%	52.21%	4
0.0004	15	20	75	160	cpu	60.78%	55.15%	5
0.0003	15	20	75	160	cpu	63.12%	54.09%	6

Všimnite si, že väčšina f1 score presnosti je približná. Keďže máme relatívne malý počet generácií, nemôžeme skutočne tvrdiť, že presnosť modelu s týmito konkrétnymi hyperparametrami by

bola práve táto presná hodnota. Vzhľadom na to, že pri malom počte generácií sa model naučí len niektoré vzory z minulých pozorovaní, ale nie všetky, a vzhľadom na to, že pri rôznych spusteníach modelu a malom počte epoch sa model pri každom spustení naučí náhodnú sadu vzorov. S rastom počtu generácií sa obe hodnoty presnosti približujú k jednej hodnote.




Experiment č. 1. Graf chyby tréovania.




Experiment č. 1. Graf testovacích chýb.

Ako je vidieť z grafu chýb tréovania prvej konfigurácie modelu, model sa učí, ale je náchylný na občasné skoky chýb. Preto vyžaduje kalibráciu. Zvýšme počet generácií, možno sa model

stabilizuje. Graf testovacích chýb zostáva približne rovnaký, pretože model sa nesmie učiť z testovacej dátovej sady. Ak však porovnáme počet minimálnych hodnôt grafu s počtom maximálnych hodnôt grafu, dostaneme priemerný výsledok, 9 minimálnych a 8 maximálnych hodnôt. To naznačuje, že model sa naučil niektoré vzory z predchádzajúcich pozorovaní a aplikoval ich (9 minimálnych hodnôt), ale niektoré z nich sa nedokázal naučiť (8 maximálnych hodnôt).



Experiment č. 2. Graf chyby tréningu.




Experiment č. 2. Graf testovacích chýb.

Po zvýšení počtu generácií (epoch) na naučenie modelu sa jeho presnosť výrazne zvýšila, ale naopak, presnosť testu prudko klesla. Máme teda nadmerné prispôsobenie. Model si zle pamätá minulé pozorovania kvôli malej veľkosti skrytej vrstvy. Zvýšime veľkosť skrytej vrstvy, aby sme zistili, či si lepšie pamätá minulé pozorovania, pričom počet epoch ponecháme relatívne malý, t. j. 50. Okrem toho graf testu ukazuje rovnaký počet minimálnych a maximálnych hodnôt.



Experiment č. 3. Graf chyby trénovania.




Experiment č. 3. Graf testovacích chýb.

Presnosť modelu na tréningovom súbore sa zvýšila, hoci testovací graf ukazuje, že je rovnaká ako v predchádzajúcom experimente. Keďže zvýšenie nebolo veľmi veľké, na grafe to nie je viditeľné. A ako je vidieť, model nemá veľmi stabilnú klesajúcu krivku, pretože sa stále učí na základe minulých pozorovaní. Model teda potrebuje viac epoch a väčšiu veľkosť skrytej vrstvy, aby si presnejšie zapamätal minulé vzory. Na to by však bolo potrebné veľa výpočtového výkonu a navyše veľa času, takže zostaneme pri počte epoch 50 a relatívne malej veľkosti skrytej vrstvy. Takže ďalším krokom je pokúsiť sa zvýšiť počet epoch, možno sa model bude lepšie učiť z minulých pozorovaní, ale v skutočnosti sa výkon môže zhoršiť, pretože máme na to pomerne malú veľkosť skrytej vrstvy a vysokú rýchlosť učenia. Urobíme to v ďalších experimentoch.



Experiment č. 4. Graf chyby tréningovania.




Experiment č. 4. Graf testovacích chýb.

Ako sa dalo očakávať, presnosť testu sa znížila, pretože rýchlosť učenia a veľkosť skrytej vrstvy zostali nezmenené. Teraz teda zvýšime veľkosť skrytej vrstvy a neskôr znížime rýchlosť učenia.



Experiment č. 5. Graf chyby tréovania.




Experiment č. 5. Graf testovacích chýb.

Po zvýšení veľkosti skrytej vrstvy sa model začal učiť minulé vzory o niečo lepšie. A pri poslednom pokuse znížime rýchlosť učenia, aby sa model učil pomalšie, dlhšie a viac (vd'aka zvýšenej veľkosti skrytej vrstvy).



Experiment č. 6. Graf chyby trénovania.



Experiment č. 6. Graf testovacích chýb.

Po znížení rýchlosti učenia je zrejmé, že počet epoch je príliš malý a je potrebné ho zvýšiť. Na to by sme však potrebovali ešte viac pokusov (experimentov), aby sme určili najlepší model, pravdepodobne nekonečné množstvo.

Úsudok

Záverom teda je, že najlepší model s najlepšimi výsledkami má presnosť testu ~59 %, čo je stredný až nízky výsledok, ale ak by sme parametre naladili podľa tabuľky veľakrát, presnosť modelu na doteraz neznámych údajoch by sa výrazne zvýšila.

Najúspešnejšia architektúra modelu má teda 3 skryté vrstvy s veľkosťou každej vrstvy 128, s veľkosťou dávky 15, počtom časových značiek v sekvencii 20, epochami 50 a rýchlosťou učenia 0,0004.